

Глубокое обучение

Коломейцева Катерина



Занятие 3: Batch Normalization & Dropout

Agenda

- Batch Normalization
- Dropout
- Еще эвристики для обучения нейросетей


Batch Normalization, она же Батч-нормализация

Стандартизация




Какая из ситуаций лучше для SGD?

А что внутри?



А что внутри?




Проблема

- Давайте вместо X на входе использовать $\frac{X - \mu_X}{\sigma_X}$
- Даже если мы стандартизовали вход X , внутри сетки может произойти несчастье и скрытый слой окажется нестандартизован
- Скрытые представления $h = XW + b$ могут менять своё распределение, что осложняет процесс обучения

Проблема

- Давайте вместо X на входе использовать $\frac{X - \mu_X}{\sigma_X}$
- Даже если мы стандартизовали вход X , внутри сетки может произойти несчастье и скрытый слой окажется нестандартизован
- Скрытые представления $h = XW + b$ могут менять своё распределение, что осложняет процесс обучения
- Давайте на каждом слое вместо h использовать $\hat{h} = \frac{h - \mu_h}{\sigma_h}$
- На выход будем выдавать $\beta \cdot \hat{h} + \gamma$, для того, чтобы у нас было больше свободы, параметры β и γ тоже учим

Batch norm (2015)



Алгоритм Batch Normalization при обучении

Input: Values of x over a mini-batch: $\mathcal{B} = \{x_1 \dots x_m\}$;

Parameters to be learned: γ, β

Output: $\{y_i = \text{BN}_{\gamma, \beta}(x_i)\}$

$$\mu_{\mathcal{B}} \leftarrow \frac{1}{m} \sum_{i=1}^m x_i \quad // \text{ mini-batch mean}$$

$$\sigma_{\mathcal{B}}^2 \leftarrow \frac{1}{m} \sum_{i=1}^m (x_i - \mu_{\mathcal{B}})^2 \quad // \text{ mini-batch variance}$$

$$\hat{x}_i \leftarrow \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}} \quad // \text{ normalize}$$

$$y_i \leftarrow \gamma \hat{x}_i + \beta \equiv \text{BN}_{\gamma, \beta}(x_i) \quad // \text{ scale and shift}$$

Batch Normalization при инференсе

- Откуда взять μ_h и σ_h при инференсе?
- Оценить по каждому из батчей и усреднить определенным образом!
- На этапе валидации используются среднее и дисперсия, посчитанные по всей train выборке


$$\mu_h = \alpha \cdot \mu_{\mathcal{B}} + (1 - \alpha) \cdot \mu_{h-1}$$

$$\sigma_h^2 = \alpha \cdot \sigma_{\mathcal{B}}^2 + (1 - \alpha) \cdot \sigma_{h-1}^2$$

- Коэффициенты β и γ оцениваются в ходе обратного распространения ошибки
- Обучение довольно сильно ускоряется, сходимость улучшается

Backward pass

Стоит обратить внимание, что β и γ - НЕ гиперпараметры, а обучаемые веса



$$\frac{\partial \ell}{\partial \hat{x}_i} = \frac{\partial \ell}{\partial y_i} \cdot \gamma$$

$$\frac{\partial \ell}{\partial \sigma_B^2} = \sum_{i=1}^m \frac{\partial \ell}{\partial \hat{x}_i} \cdot (x_i - \mu_B) \cdot \frac{-1}{2} (\sigma_B^2 + \epsilon)^{-3/2}$$


$$\frac{\partial \ell}{\partial \mu_B} = \left(\sum_{i=1}^m \frac{\partial \ell}{\partial \hat{x}_i} \cdot \frac{-1}{\sqrt{\sigma_B^2 + \epsilon}} \right) + \frac{\partial \ell}{\partial \sigma_B^2} \cdot \frac{\sum_{i=1}^m -2(x_i - \mu_B)}{m-1}$$

$$\frac{\partial \ell}{\partial x_i} = \frac{\partial \ell}{\partial \hat{x}_i} \cdot \frac{1}{\sqrt{\sigma_B^2 + \epsilon}} + \frac{\partial \ell}{\partial \sigma_B^2} \cdot \frac{2(x_i - \mu_B)}{m-1} + \frac{\partial \ell}{\partial \mu_B} \cdot \frac{1}{m}$$


$$\frac{\partial \ell}{\partial \gamma} = \sum_{i=1}^m \frac{\partial \ell}{\partial y_i} \cdot \hat{x}_i$$

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^m \frac{\partial \ell}{\partial y_i}$$

Batch norm, еще одна красивая картинка



Эксперимент с MNIST



Источник: Николенко, страница 160

Важные замечания

- С батч-нормализацией нужно уменьшить силу Dropout и регуляризацию
- Не забывайте перемешивать обучающую выборку перед каждой новой эпохой, чтобы батчи были разнообразными

http://openaccess.thecvf.com/content_CVPR_2019/papers/Li_Understanding_the_Disharmony_Between_Dropout_and_Batch_Normalization_by_Variance_CVPR_2019_paper.pdf

Dropout



Overfitting
?!?



Too many
neurons




Not
enough
DATA



BAD
Network

Dropout

- С вероятностью p отключаем нейрон
- Делает нейроны более устойчивыми к случайным возмущениям
- Борьба с ко-адаптацией, не все соседи похожи, не все дети похожи на родителей



Dropout в формулах

- forward pass:

$$o = f(X \cdot W + b)$$

* - elementwise multiplication, т.е. поэлементное умножение

Dropout в формулах

- forward pass:

$$o = f(X \cdot W + b)$$

$$o = D * f(X \cdot W + b), \quad D = (D_1, \dots, D_k) \sim iidBern(p)$$

* - elementwise multiplication, т.е. поэлементное умножение

Dropout в формулах

- forward pass:

$$o = f(X \cdot W + b)$$

$$o = D * f(X \cdot W + b), \quad D = (D_1, \dots, D_k) \sim iid Bern(p)$$


$$o_i = D_i \cdot f(wx_i^T + b) = \begin{cases} f(wx_i^T + b), p \\ 0, 1 - p \end{cases}$$

Дропаут — это просто небольшая модификация функции активации


* - elementwise multiplication, т.е. поэлементное умножение

Смысл Dropout: усреднение работы нескольких сетей

- При обучении мы домножаем часть выходов на D_i , тем самым мы изменяем только часть параметров и нейроны учатся более независимо
- Dropout эквивалентен обучению 2^n сетей



(a) Standard Neural Net



(b) After applying dropout.

Смысл Dropout: усреднение работы нескольких сетей

- При обучении мы домножаем часть выходов на D_i , тем самым мы изменяем только часть параметров и нейроны учатся более независимо
- Dropout эквивалентен обучению 2^n сетей
- Что делать на стадии инференс?

Смысл Dropout: усреднение работы нескольких сетей

- При обучении мы домножаем часть выходов на D_i , тем самым мы изменяем только часть параметров и нейроны учатся более независимо
- Dropout эквивалентен обучению 2^n сетей
- Нам надо симитировать работу такого ансамбля: можно отключать по очереди все возможные комбинации нейронов, получить 2^n прогнозов и усреднить их

Смысл Dropout: усреднение работы нескольких сетей

- При обучении мы домножаем часть выходов на D_i , тем самым мы изменяем только часть параметров и нейроны учатся более независимо
- Dropout эквивалентен обучению 2^n сетей
- Нам надо симитировать работу такого ансамбля: можно отключать по очереди все возможные комбинации нейронов, получить 2^n прогнозов и усреднить их
- Но лучше просто брать по дропауту математическое ожидание

$$o = p \cdot f(X \cdot W + b)$$

Inverted Dropout

- При инференсе ищем математическое ожидание:

$$o = p \cdot f(X \cdot W + b)$$

Inverted Dropout

- При инференсе ищем математическое ожидание:

$$o = p \cdot f(X \cdot W + b)$$

- Это неудобно! Надо переписывать функцию для прогнозов!

Inverted Dropout

- При инференсе ищем математическое ожидание:

$$o = p \cdot f(X \cdot W + b)$$

- Это неудобно! Надо переписывать функцию для прогнозов!
- Давайте лучше будем домножать на $\frac{1}{p}$ на этапе обучения (техника Inverted Dropout):

$$\text{train: } o = \frac{1}{p} \cdot D * f(X \cdot W + b)$$

$$\text{test: } o = f(X \cdot W + b)$$

Inverted Dropout:

<https://www.coursera.org/lecture/deep-neural-network/dropout-regularization-eM33A>

* - elementwise multiplication, т.е. поэлементное умножение

Почему Inverted Dropout работает?

- Рассмотрим для примера 4-ый слой в нейросети

$$z^{[4]} = w^{[4]} \cdot a^{[3]} + b^{[4]}$$

- $a^{[3]}$ - это выход с 3-го слоя

$$a^{[3]} = f(w^{[3]} \cdot a^{[2]} + b^{[3]}) * d^{[3]}, \quad d^{[3]} = \begin{cases} 1, p \\ 0, 1 - p \end{cases}$$

- пусть $p = 0.8$, тогда 20% нейронов занулятся, т.е. $\mathbb{E}\{a^{[3]}\}$ уменьшится на 20%
- чтобы этого избежать будем делить $a^{[3]}$ на p на этапе обучения

* - elementwise multiplication, т.е. поэлементное умножение

Другие эвристики для обучения сеток

Предобучение

- **На будущее:** обучаем на корпусе картинок автокодировщик, encoder благодаря этому учится выделять наиболее важные фичи, которые позволяют эффективно сжимать изображения. После срезаем decoder и на его месте достраиваем слои для решения нашей задачи, запускаем обычное дообучение.

Динамическое наращивание сети

- Обучение сети при заведомо недостаточном числе нейронов H
- После стабилизации функции потерь — добавление нового нейрона и его инициализация путём обучения
 - либо по случайной подвыборке
 - либо по объектам с наибольшими значениями потерь
 - либо по случайному подмножеству входов
 - либо из различных случайных начальных приближений
- Снова итерации BackProp

Эмпирический опыт: Общее время обучения обычно лишь в 1.5 — 2 раза больше, чем если бы в сети сразу было итоговое число нейронов. Полезная информация, накопленная сетью не теряется при добавлении нейронов.


Прореживание сети

- Начать с большого количество нейронов и удалять незначимые по какому-нибудь критерию
- **Пример:** обнуляем вес, смотрим как сильно упала ошибка, сортируем все связи по этому критерию, удаляем N наименее значимых
- После прореживания снова запускаем backprop
- Если качество модели сильно упала, надо вернуть последние удалённые связи

Более понятные идеи:

- Ранняя остановка процесса обучения
- l_1 и l_2 регуляризация
- Различные новые градиентные спуски, ускоряющие процедуру сходимости

Early stopping



- Будем останавливать обучение, когда качество на валидации начинает падать

Регуляризация

- L_2 : приплюсовываем к функции потерь $\lambda \cdot \sum w_i^2$
- L_1 : приплюсовываем к функции потерь $\lambda \cdot \sum |w_i|$
- Можно регуляризовать не всю сетку, а отдельный нейрон или слой
- Не даёт нейрону сфокусироваться на слишком выделяющемся входе

Взаимное использование изученных техник

- На практике для регуляризации обычно используют Dropout.
- Например, в [1] написано:

«We show that the dropout regularizer is first-order equivalent to an L2 regularizer applied after scaling the features by an estimate of the inverse diagonal Fisher information matrix»
- У Гудфеллоу в Глубоком обучении на стр. 218 можно найти, что ранняя остановка для линейных моделей эквивалентна l_2 регуляризации с MSE, обучаемой SGD.

[1] <https://arxiv.org/abs/1307.1493>

Что еще помогает при обучении сетей

В дальнейшем пройдем:

- Сkip-конекшены
- Аугментация данных
- Более изощренные архитектуры

Семинар с практикой по BatchNorm & Dropout